

Metriikat käytänteiden tukena ohjelmiston laadun arvioimisessa

Kasper Hirvikoski

Aine - Luonnosversio
Helsingin Yliopisto
Tietojenkäsittelytieteen laitos

Helsinki, 11. helmikuuta 2013

Sisältö

1	Johdanto	2
2	Laadullinen arviointi	2
3	Metriikat	4
3.1	Koodikirnu	4
3.1.1	Ohjelmiston virheherkkyyteen vaikuttavat mitat . . .	4
3.1.2	Johtopäätökset koodikirnusta	7
3.1.3	Koodikirnun pätevyyteen vaikuttavia tekijöitä	7
3.2	Verkkometriikat	8
3.3	Testikattavuus	8
4	Kehittäjien käytänteet	8
4.1	Ketterä kehitys	8
4.2	Versionhallinta	8
4.3	Testilähtöinen kehitys	8
4.4	Pariohjelmointi	8
5	Metriikat käytänteiden tukena	8
6	Yhteenveto	8
7	Lähteet	8

1 Johdanto

Ohjelmistot kehittyvät elinkaarensa aikana muun muassa uusien vaatimusten, optimisaatioiden, tietoturvaparannusten ja virhekorjausten johdosta. Kehitysvaiheessa olevan ohjelmiston laadun varmistaminen on hankalaa [NB05, ZN08, MNDT09]. Ohjelmiston testaamisen ja käytännössä havaittujen virheiden välillä on usein suuri kuilu. Virheiden määrää ei yleensä pystytä laskemaan luotettavasti ennen kuin tuote on valmis ja julkaistu asiakkaalle. Tässä piilee kuitenkin ongelman ydin: virheiden korjaaminen kehityksen lopussa on usein erittäin kallista.

On selvää, että laadun varmistaminen ja mahdollisten ongelmakohtien havaitseminen mahdollisimman aikaisessa vaiheessa hyödyttää kehitystyötä suuresti. Ohjelmiston koodin takana on aina ihminen. Laadun takeeksi ei voida luetella pelkästään mekaanisia, laatua arvioivia metriikoita. Kehittäjän käytänteillä on suuri laadullinen merkitys ohjelman kehitysvaiheissa.

2 Laadullinen arviointi

Laadun varmistamista rajaa ohjelmistokehityksessä aika ja raha [ZN08]. Kehittäjät kohtaavat usein tiukkoja määräaikoja ja rajallisia henkilöresursseja laadun takaamiseen. Johtavat käyttävät omakohtaisia kokemuksiaan resursien tehokkaaseen jakamiseen. Monimutkaisiin komponentteihin on syytä varata enemmän aikaa että rahaa. Komponenttien testausta ja tarkastusta tulee ohjata näihin osa-alueisiin. Johtajilla ei kuitenkaan ole läheskään aina tarvittavaa tietoa tai kokemusta, joiden pohjalta päätöksiä voitaisiin järkevästi tehdä. Päätökset tehdään usein odotusten mukaan ja näin ollen johtajat itse arvioivat laatua.

Erilaiset metriikat tarjoavat yhden tehokkaan keinon ohjelmistojen laadun määrittelyyn. Staattisten ja dynaamisten virheenpaikannustekniikoiden johdosta virheiden laatu on muuttunut. Suurin osa virhetietokantoihin tallennetuista raporteista on nykyään luonteeltaan semanttisia, eli virheet koostuvat loogisista ongelmista [ZN08]. Metriikoiden tulee ottaa tämä huomioon.

Nagappan ja Ball esittävät suhteellisen koodikirnu-tekniikan järjestelmän virhetiheyden ennakoimiseen [NB05]. Koodikirnu (code churn) mittaa ja ilmaisee määrällisesti ohjelmiston komponentteihin kohdistuvia muutoksia tietyn ajanjakson aikana. Nagappan ja Ball tuovat esille joukon suhteellisia koodikirnu-mittayksiköitä, jotka he rinnastavat muihin muuttujiin kuten komponenttien kokoon tai muokkauksen ajalliseen pituuteen. Käyttäen apuna tilastollisia regressiomalleja, he osoittavat suhteellisten koodikirnu-mittojen kyvyn havaita järjestelmän virhetiheyden paremmin kuin ehdottomien mittojen. Väittämien tueksi he suorittivat tapaustutkimuksen, jonka kohteena oli Windows Server 2003. Samalla he osoittavat, että relatiivinen koodikirnu pystyy paikallistamaan virheherkät komponentit 89 % tarkkuudella.

Monimutkaisuusmetriikat keskittyvät harvoin komponenttien välisiin vuorovaikutussuhteisiin. Ohjelmiston komponentit riippuvat lähes aina toisista komponenteista. Järjestelmän riippuvuudet voidaankin esittää matalan tason verkkoina, jossa komponenttien keskinäiset suhteet paljastuvat.

Zimmermann ja Nagappan esittävät verkkoanalyysin suorittamista näille verkoille [ZN08]. Verkkoanalyysillä voidaan paikallistaa ohjelmiston kriittiset komponentit, jotka ovat muita virheherkempiä. Ohjelmistojen kohdalla komponentit muodostavat toimijat ja komponenttien väliset riippuvuudet toimijoiden vuorovaikutukset.

Zimmerman ja Nagappan vertasivat verkkoanalyysia ja monimutkaisuusmetriikoita Windows Server 2003:n arvioimisessa. Verkkoanalyysillä saavutetaan heidän tutkimuksensa mukaan 10 % parempi hyötyaste kuin pelkillä komponenttien monimutkaisuutta mittaavilla metriikoilla. Zimmermannin ja Nagappanin havaitsivat myös, että verkkometriikat pystyvät identifioimaan 60 % komponenteista, joita ohjelmiston kehittäjät pitävät kriittisinä. Tämä on kaksi kertaa enemmän kuin tavallisilla monimutkaisuusmetriikoilla.

Ohjelmiston kehityksessä koodin testaaminen on kriittinen osa laadun takaamista. Parhaassa tapauksessa testit löytävät virheet ohjelmistosta ennen kuin se julkaistaan asiakkaalle. Mockus, Nagappan ja Dinh-Trong tutkivat testien laadullista arviointia keinona havaita virheherkkiä komponentteja [MNDT09]. Testien analysoimisessa tulisi keskittyä nimenomaan testien kykyyn havaita mahdollisia virheitä ohjelmistosta. On selvää, että taitavat kehittäjät todennäköisesti tuottavat tehokkaampia testejä, mutta testien arvioiminen määrällisesti ja laadullisesti on kannattavaa automaattisesti. Yleisin testien tehokkuutta arvioiva mittari on testikattavuus.

Testikattavuuden lajeja on useita. Yksinkertaisista luokka-, funktio-/metodi- ja käskykattavuuksista kehittyneisiin haara- ja polkukattavuuksiin. Taustalla on oletamus, että jos jokin yksittäinen ehto tai polku ei ole katettu vähintään yhdellä testillä, ei sen mahdollisesti sisältämiä virheitä pystytä havaitsemaan [MNDT09]. Tästä seuraa se, että suurempi testikattavuus löytää todennäköisesti enemmän virheitä ja takaa näin ollen parempaa laatua. Kattavuus kuvaa yksinkertaisesti osuutta siitä kuinka monta riviä ohjelmakoodia on katettu sitä testaavalla testikoodilla. Se ei pysty arvioimaan kuinka todennäköisesti nämä rivit aiheuttavat virheen. Suuri testikattavuus ei siis yksinään takaa laatua. On kuitenkin selvää, että se auttaa laadun takaamisessa. Muita metriikoita tulisi käyttää kohdentamaan testejä kriittisiin osa-alueisiin.

Ohjelmiston koodin takana on aina ihminen. Laadun takeeksi ei voida luetella pelkästään mekaanisia laatua arvioivia metriikoita. Kehittäjän käytänteillä on suuri laadullinen merkitys ohjelman kehitysvaiheissa. Ohjelmistotuotantomenetelmät nousevat suureen rooliin. Niiden tulisi ohjata laadukasta kehitystä. Vanhojen raskaaseen ennakkosuunniteluun pohjautuvien menetelmien, kuten vesiputousmallin, rinnalla on noussut uusia ketterän kehityksen malleja. Ne painottavat yksilöitä ja yksilöiden vuorovaikutus-

ta, toimivan ohjelmiston merkitystä, asiakkaan merkitystä kehitysprosessin kriittisenä osana ja muutoksiin sopeutuvaa kehitystä [BBvB⁺01]. Useat tutkimukset tukevat ketterien kehitysmallien hyötyä merkittävänä laadullisina tekijänä [SS10].

3 Metriikat

3.1 Koodikirnu

Nagappan ja Ball esittävät ohjelmistojen virhetiheyden arvioimiseen ratkaisuksi koodikirnua [NB05]. Se mittaa ohjelmiston komponenttien ohjelmakoodiin kohdistuvien muutosten määrää tietyn ajanjakson aikana. Muutosten määrä on helposti ohjelmiston versiohallintajärjestelmien muutoshistorias-ta. Useimmat versiohallintajärjestelmät vertailevat lähdekooditiedostojen historiaa ja laskevat automaattisesti koodiin kohdistuvia muutoksia. Nämä muutokset ilmentävät kuinka monta riviä tiedostoon on ohjelmoijan toimesta lisätty, poistettu tai muutettu sitten viimeiseen versiohistoriaan tallennetun version. Nämä muutokset muodostavat koodikirnun pohjan.

Nagappan ja Ball esittävät joukon suhteellisia koodikirnu-mittoja virhetiheyden havaitsemiseen. Mitat ovat normalisoituja arvoja koodikirnun aikana saaduista tuloksista. Normalisoinnilla niistä on pyritty poistamaan mahdolliset häiriötekijät. Näitä mittoja on muun muassa yhteenlaskettujen koodirivien määrä, tiedostojen muutokset ja tiedostojen määrä. Tutkimukset ovat osoittaneet, että ehdottomat mittayksiköt, kuten pelkkä koodirivien summa, ovat huonoja ohjelmiston laadullisia ennusteita. Yleisesti ottaen ohjelmiston kehitysprosessia mittaavien yksiköiden on havaittu olevan parempia osoittimia vikojen määrästä kuin pelkkää koodia arvioivat tekijät.

Ohjelmistoa kehitettäessä sen komponenttien monimutkaisuus muuttuu. Monimutkaisuuden kasvun suhde on hyvä mittari virheherkkyyden kasvulle. Koodikirnu-mittojen on havaittu korreloivan selvästi ohjelmistoista tehtyjen vikailmoitusten kanssa. Mittojen välillä on havaittavissa myös keskinäisiä suhteita, joita voidaan mallintaa verkkoina. Yksinään kyseiset mittarit eivät välttämättä tuota toivottua tulosta. Näin ollen mittoja verrataan keskenään mahdollisten ristiriitaisuuksien havaitsemiseksi. On kuitenkin selvää, että johtopäätöksiin päätyminen on hankalaa empiirissä tutkimuksissa, koska prosessien taustalla on usein laajoja kontekstisidonnaisia tekijöitä.

3.1.1 Ohjelmiston virheherkkyyteen vaikuttavat mitat

Nagappan ja Ball listaavat seuraavat ehdottomat mitat koodikirnun poh-jaksi. Nämä muodostavat suhteellisille mitoille vertailukohtat ohjelmiston virheherkkyyden analysoimisessa. Ehdottomat mitat eivät yksinään tuota luotettavaa tulosta.

Yhteenlaskettu koodirivien määrä, ohjelman uuden version ei-kommentoitujen koodirivien summa kaikkien lähdekooditiedostojen kesken.

Käsiteltyjen koodirivien määrä, ohjelman lähdekoodiin lisättyjen ja muutuneiden koodirivien summa edelliseen versioon nähden.

Poistettujen koodirivien määrä, ohjelman lähdekoodista poistettujen koodirivien määrä edelliseen versioon nähden.

Tiedostojen määrä, yhden ohjelman kääntämiseen tarvittavien lähdekooditiedostojen määrä.

Muutosten ajanjakso, yhteen tiedostoon kohdistuneiden muutosten ajanjakson pituus.

Muutosten määrä, ohjelman tiedostoihin kohdistuneiden muutosten määrä edelliseen versioon nähden.

Käsiteltyjen tiedostojen määrä, ohjelman käsiteltyjen tiedostojen yhteenlaskettu määrä.

Näiden pohjalta he muodostivat kahdeksan suhteellista koodikirnu-mittaa ja osoittivat, että nämä mitat korreloivat selvästi kohonneeseen virhemäärään koodirivejä kohden. He käyttivät Spearmanin järjestyskorrelaatiokerrointa, joka kuvaa kahden asian keskinäistä vastaavuutta. Analyysissään he havaitsivat suhteellisten mittojen ylivertaisuuden ehdottomiin verrattuna. Empiiristen tutkimusten avulla he havaitsivat seuraavien mittojen soveltuvuuden todellisen virhetiheyden ennakoimiseen.

1. Käsiteltyjen koodirivien määrä / Yhteenlaskettu koodirivien määrä

Suurempi osa käsiteltyjä koodirivejä suhteessa yhteenlaskettuun koodirivien määrään vaikuttaa yksittäisen ohjelman virhetiheyteen.

2. Poistettujen koodirivien määrä / Yhteenlaskettu koodirivien määrä

Suurempi osa poistettuja koodirivejä suhteessa yhteenlaskettuun koodirivien määrään vaikuttaa yksittäisen ohjelman virhetiheyteen. Nagapan ja Ball havaitsivat korkean korrelaation mittojen 1. ja 2. välillä.

3. Käsiteltyjen tiedostojen määrä / Tiedostojen määrä

Suurempi osa käsiteltyjä tiedostoja suhteessa ohjelman rakentavien tiedostojen lukumäärään lisää todennäköisyyttä, että nämä käsitellyt tiedostot aiheuttavat uusia vikoja. Esimerkiksi meillä on kaksi ohjelmaa A ja B, jotka molemmat koostuvat 20 lähdekooditiedostosta. A sisältää viisi käsiteltyä tiedostoa ja B kaksi. Todennäköisyys sille,

että muutokset ohjelmaan A saattavat aiheuttaa uusia vikoja on siis suurempi.

4. Muutosten määrä / Käsiteltyjen tiedostojen määrä

Mitä suurempi määrä yksittäisiin tiedostoihin on kohdistunut muutoksia, sitä suurempi on todennäköisyys sille, että tämä vaikuttaa kyseisistä lähdekooditiedostoista muodostuvan ohjelman virhetiheuteen. Esimerkiksi jos ohjelman A viittä lähdekooditiedostoa on muutettu 20 kertaa ja ohjelman B viittä tiedostoa on muutettu kymmenen kertaa, todennäköisyys sille, että ohjelma A sisältää uusia vikoja on suurempi.

5. Muutosten ajanjakso / Tiedostojen määrä

Mitä pitempi aika on kulutettu muutoksiin, jotka kohdistuvat pieneen joukkoon tiedostoja, sitä suurempi on todennäköisyys sillä, että nämä tiedostot sisältävät monimutkaisia rakenteita. Monimutkaisuus vaikuttaa koodin helppoon ylläpidettävyyteen ja näin ollen lisää näiden tiedostojen aiheuttamaa virhetihelyä.

6. Käsiteltyjen ja poistettujen koodirivien määrä / Muutosten ajanjakso

Käsiteltyjen ja poistettujen koodirivien määrä suhteessa muutosten ajanjaksoon mittaa muutoksen määrää, jota pelkkä muutosten ajanjakso ei yksinään ilmaise. Tätä mittaa tulee verrata mittaan 5. Oletuksena on, että mitä suurempi määrä käsiteltyjä ja poistettuja koodirivejä on, sitä pitempi muutosten ajanjakson tulisi olla. Tämä taas vaikuttaa ohjelman virhetiheuteen.

7. Käsiteltyjen koodirivien määrä / Poistettujen koodirivien määrä

Ohjelmiston kehitys ei koostu pelkästään vikojen korjaamisesta vaan myös uuden kehittämisestä. Uusien ominaisuuksien kehittämisessä käsiteltyjen koodirivien määrä on suhteessa suurempi kuin poistettujen koodirivien määrä. Suuri arvo tälle mitalle ilmaisee uutta kehitystä. Saatua arvoa verrataan mittoihin 1. ja 2., jotka yksinään eivät ennakoivat uutta kehitystä.

8. Käsiteltyjen ja poistettujen koodirivien määrä / Muutosten määrä

Mitä suurempi muutoksen laajuus on suhteessa muutosten määrään, sitä suurempi virhetiheys on. Mitta 8. toimii verrokkina mitoille 3.-6. Suhteessa mittoihin 3. ja 4., mitta 8. ilmaisee todellisen muutoksen määrää. Se kompensoi sitä tietoa, että yksittäisiä tiedostoja ei käsitellä toistuvasti pienten korjausten takia. Suhteessa mittoihin 5. ja 6., mitä suurempi käsiteltyjen ja poistettujen koodirivien määrä on käsittelyä

kohden, sitä pitempi muutosten ajanjakso tarvitaan ja sitä enemmän muutoksia kohdistuu esimerkiksi jokaista viikkoa kohden. Muussa tapauksessa suuri määrä muutoksia on saattanut kohdistua hyvin lyhyeen ajanjaksoon, joka ennakoii suurempaa virheterkeyttä.

3.1.2 Johtopäätökset koodikirnusta

Nagappan ja Ball havaitsivat, että koodi joka muuttuu useasti ennen julkaisua on selvästi virheherkempää kuin koodi, joka muuttuu vähemmän saman ajanjakson aikana. He tutkivat kahden ohjelmistojulkaisun Windows Server 2003 ja Windows Server 2003 Service Pack 1 pohjalta saatuja tuloksia. Julkaisuista analysoitiin 44,97 miljoonaa riviä koodia, joka muodostui 96 189 lähdekooditiedostosta. Niistä käännettiin 2 465 yksittäistä ohjelmaa.

He päätyivät tutkimuksessaan neljään johtopäätökseen:

1. Suhteellisten koodikirnu-mittojen nousua seuraa ohjelmiston virheherkkyyden kasvu.
2. Suhteelliset mitat ovat parempia laadullisia arvioijia kuin ehdottomat mitat.
3. Suhteellinen koodikirnu on tehokas tapa arvioida ohjelmiston virheherkkyyttä.
4. Suhteellinen koodikirnu pystyy havaitsemaan virheherkän ja toimivan komponentin toisistaan.

3.1.3 Koodikirnun pätevyyteen vaikuttavia tekijöitä

Nagappan ja Ball toteavat, että mittausvirheet vaikuttavat arvion luomiseen. Ongelma ei ole kuitenkaan suuri, sillä versiohallintajärjestelmät hoitavat automaattisesti analyysiin vaadittavat lähtöarvot. Koodikirnu vaatii kuitenkin myös ohjelmiston kehittäjältä hyviä käytäntöjä. Jos kehittäjä on tehnyt useita muutoksia rekisteröimättä niitä versiohallintajärjestelmän historiaan, osa muutoksista jää näkemättä. Kehittäjän toimista riippuen myös muutosten ajanjakson pituus voi selvästi pidentyä, jos muutoksia ei hyväksytä tarpeeksi aikaisin versiohallintajärjestelmään. Mittojen vertaaminen keskenään lieventää tästä johtuvia poikkeamia.

He toteavat myös, että tapaustutkimuksen pätevyyteen voidaan nähdä vaikuttavan myös sen tosiasian, että tutkimuksessa analysoitiin vain yhtä ohjelmistojärjestelmää. Tämä ohjelmistojärjestelmä kuitenkin koostuu lukuisista komponenteista ja suuresta määrästä koodia. Analyysi on siis itsessään erittäin kattava.

3.2 Verkkometriikat

Verkkometriikat tarkemmin.

3.3 Testikattavuus

Testikattavuus tarkemmin.

4 Kehittäjien käytänteet

Ohjelmiston koodin takana on aina ihminen! Kehittäjien käytänteillä ja kehitysmalleilla on siis suuri merkitys.

4.1 Ketterä kehitys

Scrum, XP, jne.

4.2 Versionhallinta

”Commit early, commit often.”

4.3 Testilähtöinen kehitys

Testilähtöisen kehityksen hyödyt ja haitat.

4.4 Pariohjelmointi

Pariohjelmoinnin hyödyt ja haitat.

5 Metriikat käytänteiden tukena

Rinnastetaan metriikat käytänteiden tueksi.

6 Yhteenveto

Ohjelmiston koodin takana on aina ihminen. Selvästi siis laadun takeeksi ei voida luetella pelkästään mekaanisia laatua arvioivia metriikoita. Kehittäjän käytänteillä on suuri laadullinen merkitys ohjelman kehitysvaiheissa.

7 Lähteet

[BBvB⁺01] Beck, Kent, Mike Beedle, Arie van Bennekum, Alistair Cockburn, Ward Cunningham, Martin Fowler, James Grenning, Jim Highsmith, Andrew Hunt, Ron Jeffries, Jon Kern, Brian Marick,

Robert C. Martin, Steve Mellor, Ken Schwaber, Jeff Sutherland ja Dave Thomas: *Manifesto for Agile Software Development*, 2001. <http://agilemanifesto.org/>.

- [MNDT09] Mockus, A., N. Nagappan ja T.T. Dinh-Trong: *Test coverage and post-verification defects: A multiple case study*. Teoksessa *Empirical Software Engineering and Measurement, 2009. ESEM 2009. 3rd International Symposium on*, sivut 291–301, oct. 2009. http://ieeexplore.ieee.org/xpls/abs_all.jsp?arnumber=5315981.
- [NB05] Nagappan, Nachiappan ja Thomas Ball: *Use of relative code churn measures to predict system defect density*. Teoksessa *Proceedings of the 27th international conference on Software engineering, ICSE '05*, sivut 284–292, New York, NY, USA, 2005. ACM, ISBN 1-58113-963-2. <http://doi.acm.org/10.1145/1062455.1062514>.
- [SS10] Sfetsos, P. ja I. Stamelos: *Empirical Studies on Quality in Agile Practices: A Systematic Literature Review*. Teoksessa *Quality of Information and Communications Technology (QUATIC), 2010 Seventh International Conference on the*, sivut 44–53, oct. 2010. http://ieeexplore.ieee.org/xpls/abs_all.jsp?arnumber=5654783.
- [ZN08] Zimmermann, Thomas ja Nachiappan Nagappan: *Predicting defects using network analysis on dependency graphs*. Teoksessa *Proceedings of the 30th international conference on Software engineering, ICSE '08*, sivut 531–540, New York, NY, USA, 2008. ACM, ISBN 978-1-60558-079-1. <http://doi.acm.org/10.1145/1368088.1368161>.